Карточка модели: ИнваРадар, карта вероятности 2025

Назначение

Сузить зону поиска очагов борщевика Сосновского (*Heracleum sosnowskyi*) и золотарников (*Solidago canadensis*, *S. gigantea*) в Москве и ближнем Подмосковье и упорядочить выезды по риску для людей.

Не предназначена для того, чтобы служить единственным основанием штрафа или предписания: карта показывает, где обследование вероятнее всего найдёт куртину. Решение принимает человек по результатам осмотра или фотофиксации.

Модель

ПАРАМЕТР	ЗНАЧЕНИЕ
Тип	градиентный бустинг LightGBM 4.x, бинарная классификация «находка против фона»
Гиперпараметры	300 деревьев, learning rate 0,05, 15 листьев, min_child_samples 20, subsample 0,8, colsample 0,5, L2 1,0, вес класса — отношение фона к находкам
Инференс	Rust-ядро, обход деревьев из `dump_model()`; расхождение с LightGBM $8{,}9 \cdot 10^{-16}$
Выход	процентиль ландшафта × 250 (0–250, 255 — нет данных): доля площади зоны с меньшей оценкой
Признаки (265)	64 — эмбеддинг AlphaEarth Foundations пикселя 10 м; 3 × 64 — средние эмбеддинги в окнах 50, 150 и 450 м; 5 — ln(1 + расстояние) до магистралей, второстепенных дорог, железных дорог, воды и ЛЭП; 4 — высота, уклон, TWI, HAND (только для борщевика)
Важность групп признаков, борщевик	пиксель 15,7%; окно 50 м 26,8%; 150 м 22,7%; 450 м 26,7%; коридоры 4,7%; рельеф 3,4%

Обучающие данные

- Находки: наблюдения iNaturalist исследовательского уровня с точностью координат до 50 м, одна запись на пиксель; борщевик — 1 574, золотарник — 1 560.
- Фон: 60 000 наблюдений других сосудистых растений теми же наблюдателями в той же зоне (target-group background); фон ближе 30 м к находке исключён.
- Эмбеддинги: AlphaEarth Foundations, 2025 год.

Проверка

МЕТРИКА	БОРЩЕВИК	ЗОЛОТАРНИК
Доля находок в верхних 10% площади, блоки 5 км	25,0% (95% ДИ 20,7–28,8%)	32,5% (28,4–35,9%)
То же в верхнем 1% площади	2,5% (1,3–3,7%)	7,1% (5,1–8,8%)
ROC AUC против фона	0,686	0,690
Новые находки 2025–2026 гг. в верхних 20% площади (обучение до 2024 г.)	38,4% (33,7–43,3%), n = 383	45,7% (40,5–50,9%), n = 346
Устойчивые очаги (≥ 2 наблюдателя) в верхних 10% площади	39,8%, n = 133	—
Площадь в области применимости (Meyer & Pebesma 2021)	96,3%	95,7%

Интервалы: кластерный бутстрэп по блокам 5 км (2000 повторов) для пространственной проверки и интервал Уилсона для теста во времени (`scripts/uncertainty.py`).

Модуль БПЛА

ПАРАМЕТР	ЗНАЧЕНИЕ
Модель	замороженный DINOv2 ViT-S/14 (Apache-2.0), вход 896 пикселей по ширине; линейный классификатор по патчу 14 × 14 и его окрестности 3 × 3
Данные проверки	263 аэрофото борщевика в Подмосковье с масками, три камеры: DJI Mavic Pro, DJI Phantom 3, Xiaomi Yi [47]
Протокол	камера проверки целиком исключена из обучения; порог подбирается на двух других камерах
ROC AUC / AP по патчам	0,948 / 0,747
Режим разведки (max F2)	Dice 0,71, IoU 0,55, полнота 72,5%, точность 69,2%; борщевик найден на 216 из 251 снимков
Режим подсчёта площади (max F1)	Dice 0,66, точность 77,9%
Файлы	`outputs/drone/benchmark.json`, `outputs/drone/dinov2s_probe.joblib`; запуск — `make drone`

Границы применимости

- **Что измеряют метрики карты.** Метки — точки граждан с погрешностью до 50 м, часто одиночные растения меньше пикселя. Поэтому метрики описывают главное для заказчика — насколько карта сужает поиск. Контуры куртин даёт модуль БПЛА, площадь и точность по территории — стратифицированная полевая выборка из 250 точек (`validation_sample.csv`).
- **Смещение наблюдений.** Находки граждан сгущаются у дорог и в парках; фон из наблюдений других растений теми же людьми выравнивает это смещение, а полевая выборка его исключает.

- **Рельеф в застройке.** Copernicus DEM — модель поверхности, в плотной застройке HAND и TWI сглажены зданиями; при подключении городской ЦМР без зданий признаки пересчитываются той же командой.
- **Квантование карты.** Процентиль хранится с шагом 0,004 (uint8, ×250), поэтому «верхние 2%» для очагов и выборки — около 2,2% площади; метрики качества считаются по точным рангам.
- **Сезонность.** Эмбеддинги годовые; окна цветения добавляет модуль Sentinel-2 (каждые 5 дней). Модуль БПЛА обучен на весенних снимках листьев и розеток; для зонтиков в июле работает индекс цветения, дообучение на летних облётах — в плане сезона 2027.

Этика и право

- Методы обработки выбираются правилами `invaradar/management.py` со ссылками на ВК РФ ст. 65, СанПиН 2.1.3684-21 и 73-ФЗ; правило «100 м от детских объектов» — осторожность системы, а не норма.
- Персональные данные в модели не используются: только координаты наблюдений растений.

Воспроизведение

`make all` — данные, обе модели, варианты без рельефа и с рельефом, обогащение, интервалы и рисунки. Прогон одного вида — 13–15 минут на 4 vCPU.